

# 7. domaća zadaća iz Neizrazitog, evolucijskog i neuroračunarstva

Dominik Špiljak

## 1. Ovisnost izlaza neurona tipa 1 o parametru $s$




Figure 1: Ovisnost izlaza neurona o jednodimenzionalnom parametru  $s$

Vidljivo je da s većim  $s$ , točke koje su dalje su sličnije našoj težini  $w$ , to jest, veći  $s$  daje veće sličnosti i time veći izlaz.

## 2. Vizualizacija skupa podataka




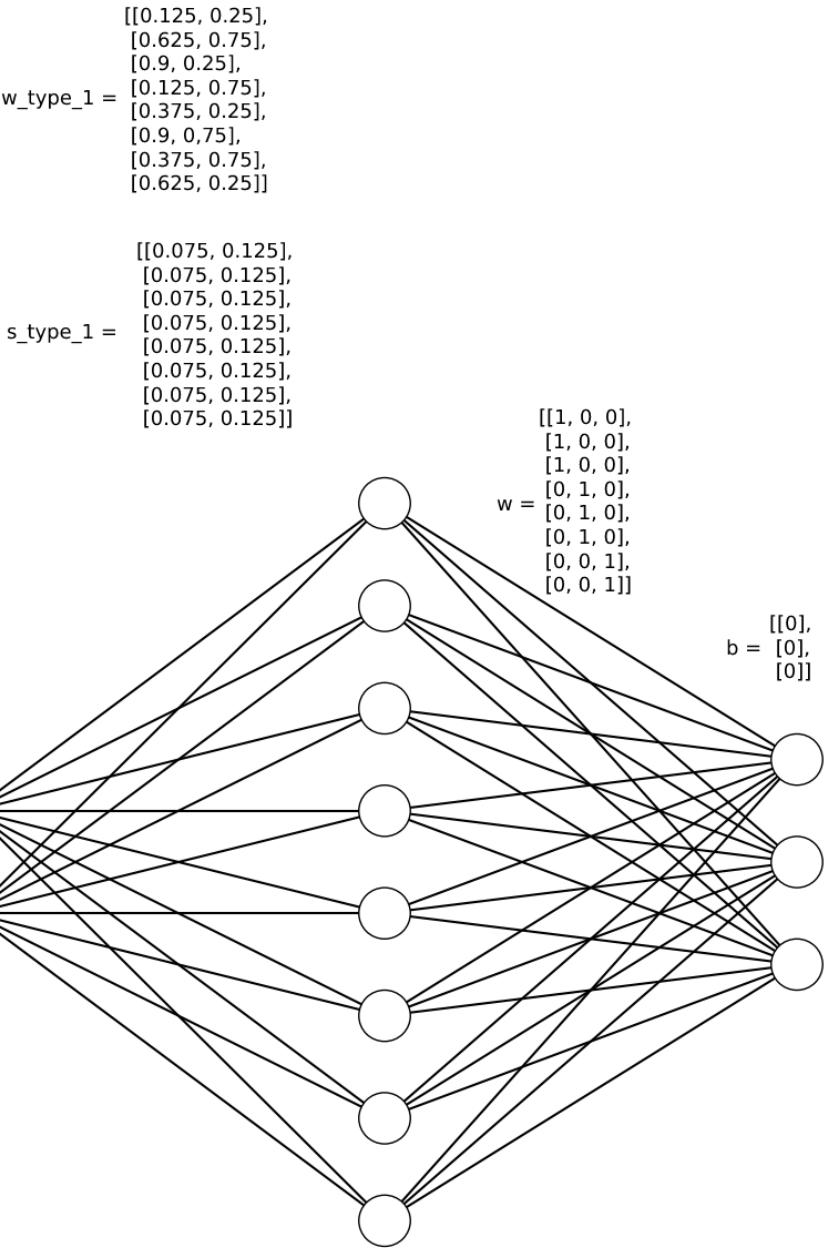
Figure 2: Vizualizacija skupa podataka "dataset.txt" koristeći matplotlib

Podaci nisu linearno odvojivi, ali postoji uzorak gdje su podaci grupirani u elipse.

## 3. Ručno određivanje parametara mreže


Ako koristimo arhitekturu 2x8x3, intuitivno je postaviti težine neurona tipa 1 u središta elipsa, namjestiti  $s[1] > s[0]$  pošto su elipse izdužene po y osi i namjestiti težine između zadnja 2 slojeva da model provodi pravilnu klasifikaciju.

Model bi otprilike izgledao ovako:



## 4. Mreža 2x8x3

Vizualizacija podataka, model: (pop\_size: 40, num\_iter: 5000000, k: 3, mutation\_choser\_probs: 10, 3, 5, mutation\_prob: 0.05, layers: 2, 8, 3)



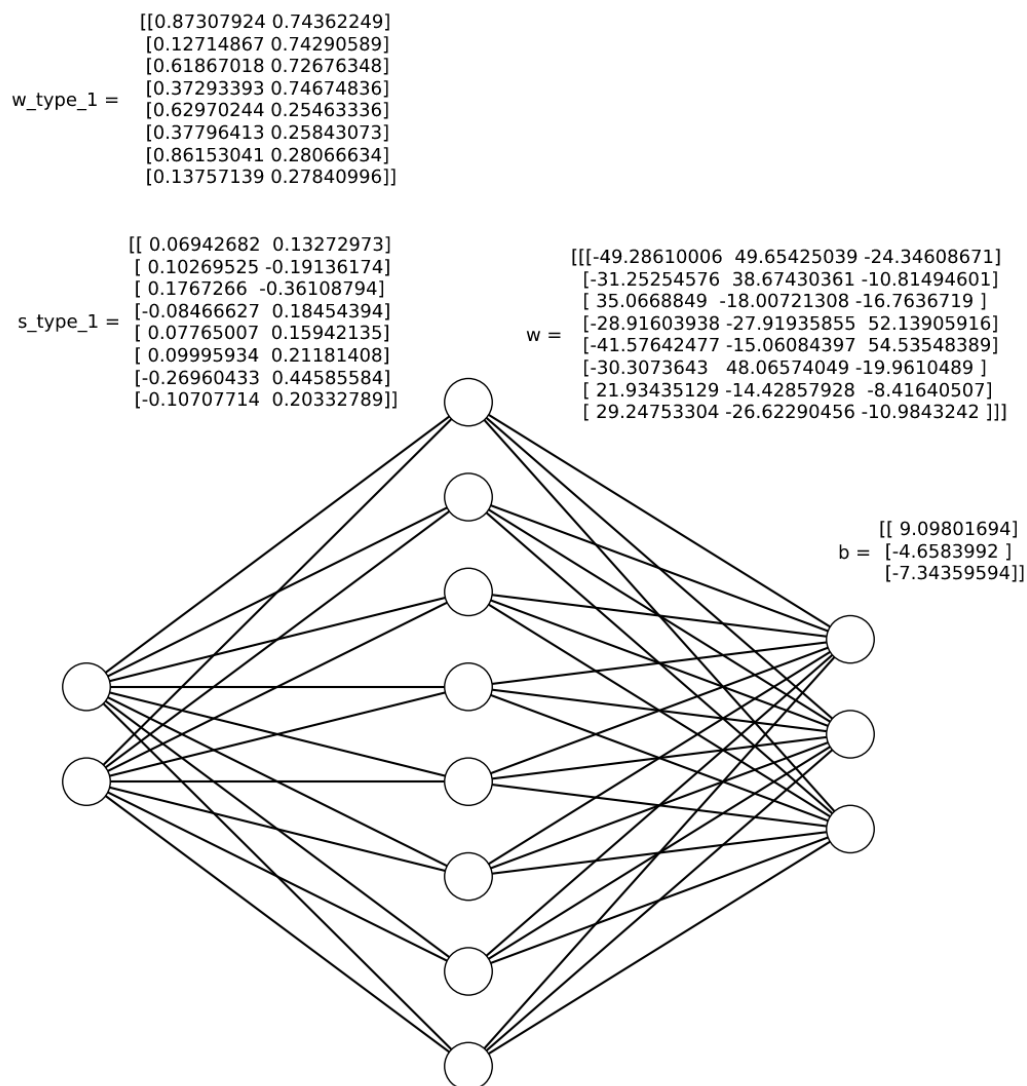
Kao što je bilo očekivano, težine u neuronima tipa 1 predstavljaju središta elipsa.

Pogledajmo sada parametre s neurona tipa 1:

```
[[ 0.06942682  0.13272973]
 [ 0.10269525 -0.19136174]
 [ 0.1767266  -0.36108794]
 [-0.08466627  0.18454394]
 [ 0.07765007  0.15942135]
 [ 0.09995934  0.21181408]
 [-0.26960433  0.44585584]
 [-0.10707714  0.20332789]]
```

Kao što je i bilo očekivano,  $|s[1]|$  je uvijek veći od  $|s[0]|$  zato što su elipse izdužene u smjeru y osi.

Nacrtajmo sad tu mrežu:




Objasnili smo parametre neurona tipa 1, pogledajmo sada težine između zadnja 2 sloja. Odmah kod velikih brojeva, možemo vidjeti da je tu mutacija igrala veliku ulogu. Kod ovih težina uočavamo pravilnosti u stupcima, koji zapravo predstavljaju ulaze u neurone zadnjeg sloja. U 1. i 2. stupcu 5 težina je negativno i 3 pozitivno, a u 3. stupcu, 6 težina je negativno i 2 pozitivno. I upravo te težine koje su pozitivne, povezuju izlazni neuron s odgovarajućim neuronima srednjeg sloja koji predstavljaju središta elipsa "clustera" tog razreda. To je bila i naša pretpostavka kada smo ručno birali parametre.

## 5. Mreža 2x8x4x3

Postupak učenja je trajao kraće od mreže arhitekture 2x8x3, što je kontraintuitivno pošto imamo više parametra koje moramo naučiti. Naime, ova mreža ne mora točno pogoditi središta elipsa jer ima još jedan sloj prije izlaznog koji težinama može kompenzirati za nepreciznost sloja s neuronima tipa 1.

Pogledajmo naučene parametre neurona tipa 1:

Vizualizacija podataka, model: (pop\_size: 40, num\_iter: 5000000, k: 3, mutation\_choser\_probs: 10, 3, 5, mutation\_prob: 0.05, layers: 2, 8, 4, 3)




Parametri s:   
[[-0.10148338 -0.71219637]  
[-0.12296905 -0.19998307]  
[-0.44130842 -0.21208499]  
[ 0.086306 0.21726107]  
[-0.13141879 0.46599151]  
[-0.10254753 0.1929195 ]  
[-0.05633663 0.06145126]  
[ 0.08176352 0.20547042]]

## 6. Mreža 2x6x4x3

Mreža je uspjela postići grešku manju od  $1e-7$ , ali smo izgubili mogućnost da objasnimo sa sigurnošću parametre neurona tipa 1, težine više nisu središta elipsa.

Pogledajmo naučene parametre neurona tipa 1:

Vizualizacija podataka, model: (pop\_size: 40, num\_iter: 5000000, k: 3, mutation\_choser\_probs: 10, 3, 5, mutation\_prob: 0.05, layers: 2, 6, 4, 3)



Parametar s:  $\begin{bmatrix} 0.07552945 & -0.1639977 \\ 0.10979425 & -0.29974527 \\ -0.10901198 & -0.11664892 \\ -0.12777444 & -0.33704279 \\ -0.29499597 & 0.60810681 \\ 0.15545808 & -0.14868363 \end{bmatrix}$